

分析進捗報告書

1. 報告サマリー

- チェックポイント: M01(キックオフ)
- チェックポイント日付: 2025-08-06(報告対象期間: 2025-08-06 to 2025-08-06)
- チェックポイント段階: kickoff(事前準備／計画段階、実装・学習未着手)※
analysis.checkpoint_stage=kickoff に準拠
- 現時点の総括:
 - キックオフ(M01)は予定通りの実施扱い(議題: 目的変数 SALE PRICE、対象データ、スコープ、役割分担、会議運営)。ただし該当議事メモは現時点で未登録(No meeting minutes found / prior_state.minutes_files = [])。
 - 実装状況: planning_only(モデル学習・評価結果は未存在／公開不可)。visible_trials は空(no_model_results)。
 - 商務トピック(Report facts に基づく): 想定総工数 170 時間、見込金額(税抜)4,250,000 円、消費税 425,000 円、見込金額(税込)4,675,000 円、支払スキームは最終一括精算(支払条件: 検収後 5 営業日以内)。

2. 進捗状況

- キックオフ(MS1)は実施済(会議 ID=M01、2025-08-06)。会議計画は artifacts/04a_meeting_plan.csv に格納。チェックポイント情報は報告事実 JSON の checkpoint に一致。
- 現フェーズの状態(要点)
 - 計画／前提固定フェーズ開始済み(スコープ・役割の明確化)。
 - データ受領・読込の検証タスク(T03)および分析計画メモ作成タスク(T05)は予定フェーズ→着手予定。
 - open_action_count は 0(報告事実 JSON.prior_state.open_action_count = 0)。
 - 実験・モデル結果の公開はなし(analysis.visible_trials = [], best_visible_trial = null)。
- スケジュールとのトレース(主要マイルストーン)
 - MS1(キックオフ完了): 2025-08-06(本チェックポイント)
 - 次ゲート: MS2(分析計画メモ確定): 2025-08-12(予定) — ここで前処理方針と品質点検観点を確定予定。

- 中間報告ゲート: MS4(中間報告承認): 2025-08-26(予定)

3. 主要な分析結果

(注)現在はキックオフ段階のため、モデル結果や最終評価指標は存在しません。以下はデータ理解フェーズでの初期観察・要確認事項です。数値の多くはプロジェクト概要に基づくため Report facts JSON に未記載の項目は「(assumption)」と明示しています。

- 目的変数関連

- 目的変数: SALE PRICE(設定済)。(config 等により target_column は SALE PRICE と確定)
- SALE PRICE のサンプル要約(参照資料ベース): レコード数 37,751(assumption)、最小 100,700(assumption)、最大 4,996,841(assumption)、平均 約 870,378.47(assumption)。分布は右に歪んでいる可能性が高く、対数変換の検討が必要。

- データ品質関連の初期発見(要対応)

- 面積項目の欠損が多い: LAND SQUARE FEET 欠損 13,262 件(assumption)、GROSS SQUARE FEET 欠損 13,555 件(assumption)。0 値も混在。
- 築年・郵便番号の異常値疑い: YEAR BUILT 最小 0、平均 $\approx 1,817.78$ (assumption)/ZIP CODE に 0 が含まれる(assumption)。入力誤・欠損代替・非開示を切り分ける必要あり。
- 建物クラス・税区分の欠損: TAX CLASS AT PRESENT 欠損 362(assumption)、BUILDING CLASS AT PRESENT 欠損 362(assumption)。
- 立地変数(BOROUGH, NEIGHBORHOOD, ZIP CODE)は価格差の主要要因と想定。BOROUGH は 1-5 のコード(Manhattan 等)で重要軸。
- 設定ミス・確認要: analysis/config において date_column が "TAX CLASS AT TIME OF SALE" に設定されている(configs/project_config.json / analysis_spec)。当該列名は日付でない可能性が高く、日付列指定の再確認が必要(未解決事項)。

- 実験状況

- 現時点で可視化された試行(visible_trials)は無し(analysis.visible_trials = [])。モデル学習・評価は実施前(implementation_status = planning_only)。

4. データ品質と実装状況

- データ品質(要点、数値は原資料に基づく/assumption 表示)

- 総レコード数: 37,751(assumption)
- 欠損/異常の注目点:
 - LAND SQUARE FEET 欠損 13,262(assumption)
 - GROSS SQUARE FEET 欠損 13,555(assumption)

- *TAX CLASS AT PRESENT, BUILDING CLASS AT PRESENT* 欠損 それぞれ 362 (*assumption*)
- *YEAR BUILT* に 0 を含む(*assumption*)
- 結論: 面積系・築年・一部カテゴリに対する補完方針／除外基準を早期に確定する必要あり(中間報告前に合意)。
- **実装・環境状況**
 - プロジェクトのコード基盤・設定ファイルは生成済(`analysis_project README`、`configs/project_config.json` 等が存在)。
 - 実行設定(`configs`)では `split_strategy=time_ordered`、`early_stopping=true` 等が設定されているが、これらを確定するためのデータ前提(有効な日付列の有無等)を確認する必要あり。
 - 現時点でモデル学習は未実行(`planning_only`)。出力可能なモデルメトリクスは存在しない(`no_model_results`)。

5. リスクと対応策

- **リスク 1: 立地起因の偏り(location-driven bias)**
 - 影響: 立地が価格変動の大半を説明し、建物属性の寄与推定が歪む可能性。
 - 対応: BOROUGH レベルで階層比較を行い、立地調整(階層固定効果等)の方針を中間報告(MS4)までに決定。担当: 渡辺(リード DS)／期限: 2025-08-26(中間報告)。
- **リスク 2: 市況(時系列)情報の欠落または誤指定(日付列誤設定)**
 - 影響: 市況サイクルを調整できず解釈が限定される。
 - 対応: `date_column` 設定の是非確認(現在: “TAX CLASS AT TIME OF SALE” → 要確認)。担当: 岡田(DE)+渡辺(DS)／期限: 2025-08-08(データ受領確認)→ 2025-08-12(計画メモ確定)。
- **リスク 3: 面積・築年等の欠損・異常値**
 - 影響: 面積をキーとする説明力低下、補完によるバイアス導入。
 - 対応: 欠損・ゼロ値の切り分けルール(除外・補完・カテゴリ化)を MS2(2025-08-12)で合意し、影響件数を明記する。担当: 渡辺／岡田。
- **リスク 4: 高カーディナリティ変数による過学習**
 - 影響: NEIGHBORHOOD や BBL 等をそのまま使うと過学習。
 - 対応: 高カーディナリティは除外または集約(階層集約／頻度エンコーディング等)を適用。方針は MS2 で決定。担当: 渡辺。
- 運用上の注意(商務)
 - 追加要求は `time_and_materials` で別途見積(Report facts/commercial に記載)。変更多発時は 2025-08-27 の変更管理チェックポイントで工数影響を明示すること。

6. 次回までの実施事項

(責任者・期限を明記してスケジュールと紐付け)

1. データ受領確認・読込検証(T03)
 - 担当: 岡田 佑樹(データエンジニア)
 - 期限: 2025-08-08(予定)
 - 成果物: 読込確認レポート(artifacts/analysis_outputs/train_preview.csv など)
2. 分析計画メモ／実施方針書の確定(MS2 / T05)
 - 担当: 藤田 彩(BA)／渡辺(DS)／小林(QA)
 - 期限: 2025-08-12(予定)
 - 成果物: 分析計画メモ(前処理方針、欠損処理基準、日付列定義を明記)
3. date_column の実態確認(設定ミスの有無確認)
 - 担当: 岡田＋渡辺
 - 期限: 2025-08-08(優先)→ 結果は分析計画メモに反映
4. 欠損・ゼロ値・異常値の件数確定(T06)
 - 担当: 岡田／渡辺
 - 期限: 2025-08-15(予定)
 - 成果物: 品質点検一覧(件数と方針)
5. 中間報告資料(EDA 図表含む)作成(T10)
 - 担当: 渡辺／藤田
 - 期限: 2025-08-25(内部レビュー)／中間報告会 2025-08-26(MS4)
6. 変更管理チェックポイントの準備(T12)
 - 担当: 佐藤(PM)
 - 期限: 2025-08-27(変更要求発生時の工数試算に備える)

※ 上記タスクはプロジェクトスケジュール(WBS)と整合。重要な締切(MS2:2025-08-12、MS3:2025-08-22、MS4:2025-08-26)を優先。

7. 経営/PM 向け補足

- 契約・商務状況(Report facts JSON に基づく)

- 契約開始日: 2025-08-06(適用開始)
- 期間: 6 週間(プロジェクト期間)
- 想定総工数: 170 時間(project_facts / commercial)
- 見込金額(税抜): 4,250,000 円、消費税: 425,000 円、見込金額(税込): 4,675,000 円(支払は最終一括精算)
- 支払スケジュール: 最終一括(支払期日: 検収後 5 営業日以内)
- 現時点での経営判断ポイント(要決定)
 1. date_column の正確な指定(分析方針と前処理に影響) — 早急な確認を推奨。
 2. 中間ゲート(2025-08-26)での前処理方針承認(欠損処理・除外基準の承認)がないとモデリング工程に着手できない旨を注意。
 3. 追加データやスコープ拡張要求がある場合、time_and_materials のため早期に見積が発生。2025-08-27 の変更管理 CP で調整を推奨。
- 当チェックポイントのエビデンス／参照ファイル
 - ミーティング企画: artifacts/04a_meeting_plan.csv
 - 分析設定: configs/project_config.json(date_column 等の設定を含む)
 - Report facts JSON(本報告は同データを基準に作成): トレース情報は artifacts/00a_project_facts.json 等に保存

備考: 本報告は analysis.checkpoint stage = “kickoff” のルールに従い、「モデル学習済・評価済」の記載は一切行っていません。モデルの学習・評価結果が可視化された段階で、visible_trials / best_visible_trial に基づく定量報告を行います。