

分析進捗報告書

1. 報告サマリー

- チェックポイント: M02(中間報告)
- 日付: 2025-08-26
- 報告対象期間: 2025-08-06 ~ 2025-08-26
- チェックポイント段階(Report facts): interim(中間分析段階)
- 現状ステータス(短報): 第1週キックオフ完了、データ受領・読込検証着手、品質点検と探索的分析を経てモデル実験(第1~第5トライアル)を実行。中間報告(MS4)で「前処理ルール案」「分析データセット化方針」「初期モデリング継続条件」の承認を受けるべく報告を実施。

2. 進捗状況

- スケジュール整合
 - キックオフ(M01): 実施済(2025-08-06) — 議事録: artifacts/meeting_minutes/会議録_2025-08-06.md
 - 中間報告(M02): 実施日 2025-08-26(本チェックポイント)
 - 次の主要予定: 変更管理チェックポイント(2025-08-27)、初期モデリング継続(第4週以降)
- 会議・決定トレース
 - 中間報告の目的は「データ品質確認結果と探索的分析結果の共有／前処理方針合意」(Report facts.checkpoint.purpose に準拠)。
- 開発・実験進捗(可視化された実験のみを引用)
 - visible_trials(trial_index 1~5)を実施済み(詳細は第3節)。
- 開放アクション(トレース)
 - prior_state.open_action_count: 8(未完了アクションが8件／詳細は第6節に列挙、Report facts prior_state より)

3. 主要な分析結果

※ 本節は Report facts JSON.analysis.visible_trials / best_visible_trial に明示されている実験結果のみを記載します。中間段階の結果であり最終結論ではありません。

- 実験サマリ(visible_trials)
 - **T01(trial_id: T01, linear_baseline)**
 - model_type: linear_baseline
 - primary_metric (rmse): 2825578.6761237755
 - secondary_metric (r2): -7.4503627353568636
 - selected_feature_count: 13, excluded_feature_count: 4
 - **T02(T02, cyclical_linear)**
 - model_type: linear_baseline(周期特徴を追加)
 - rmse: 2825578.6761237755
 - r2: -7.4503627353568636
 - selected_feature_count: 13, excluded_feature_count: 4
 - **T03(T03, hist gradient boosting)**
 - model_type: hist_gradient_boosting

- *rmse: 708753.9903292693*
 - *r2: 0.46831846615046635*
 - *selected_feature_count: 13, excluded_feature_count: 4*
- **T04(T04, log target hist gradient boosting)**
 - *model_type: hist_gradient_boosting(ターゲットに log1p を適用)*
 - *rmse: 738055.754082396*
 - *r2: 0.4234474680039092*
 - *selected_feature_count: 13, excluded_feature_count: 4*
- **T05(T05, configured default)**
 - *model_type: random_forest*
 - *rmse: 706251.4871887658*
 - *r2: 0.47206641189165033*
 - *selected_feature_count: 13, excluded_feature_count: 4*
- 現時点の「最良(可視)試行」について
 - **best_visible_trial: T05(random forest)**
 - *rmse: 706251.4871887658, r2: 0.47206641189165033*(Report facts.best_visible_trial と analysis.metrics に整合)
 - analysis.metrics に記載の MAE: 428820.1407276015(これも中間結果の指標として参照可能)
 - **コメント(中間観察):**
 - 線形ベースライン(T01/T02)は本データ特性では性能が劣後しており(rmse が非常に大きく、r2 が負の値)、非線形手法(T03/T05)の方が大幅に改善している。T03/T05 の rmse は約 7.08e5~7.06e5、r2 は約 0.47(T05)前後で安定している点が確認できる。
 - T04(ターゲットに log1p を適用した hist gradient boosting)はやや性能低下が見られ、ターゲット変換の効果は条件依存であることが示唆される。
 - **注意:** これらは中間チェックポイントで可視化されたトライアル(trial_index 1~5)の結果であり、最終モデルや最終スコアを示すものではありません(Report facts.analysis.checkpoint_stage = “interim” の方針に準拠)。

4. データ品質と実装状況

- 実行構成(参照)
 - 分析仕様の date_column 設定: “TAX CLASS AT TIME OF SALE”(configs / analysis run_summary に一致)
 - split_strategy(実行設定): time_ordered(project config に設定)
 - use_date_features: true(設定)
- データ品質(現時点で確定している論点)
 - 面積系、築年、ZIP コード等に品質懸念がある旨はキックオフで指摘済(M01 会議録)。ただし、Report facts JSON に欠損の正確な集計値は含まれていないため、件数や割合は以下のとおり扱います。
 - LAND SQUARE FEET / GROSS SQUARE FEET の欠損・ゼロ値に関する具体件数: 前段資料に数値があるが、本チェックポイントの Report facts JSON に明示されていないため「assumption(前提資料に基づく)」として扱います。正確な欠損集計は A05 の完了で確定予定(責任者: 岡田/渡辺、期限: 2025-08-15 のオリジナル要求)。
 - date_column の扱い: 設定は “TAX CLASS AT TIME OF SALE” だが、そのカラムが時系列として妥当かは検証中(M01 のアクション A03)。解析パイプラインは date_column を用いた time_ordered split を試行しているが、パース可能性に依存するため中間判定での扱いに注意が必要。
- 実装状況

- 特微量選択後の選択特微量数: 13(selected_feature_count = 13、Report facts に一致)
- 除外特微量数: 4(excluded_feature_count = 4)
- モデルパイプライン: visible_trials に示されたモデル群を v1 として実行済。early_stopping 等のパラメータは設定に依存しているため、最終調整は第 4 週以降の作業で継続予定。

5. リスクと対応策

- 主要リスク(中間時点)
 1. 立地(BOROUGH/NEIGHBORHOOD)による説明力の偏重
 - 影響: 価格差の多くが立地で説明され、建物属性の寄与解釈が不安定化
 - 対策: BOROUGH 固定効果や階層別比較を優先的にを行い、属性寄与を分離する(担当: 渡辺、次回中間以降の作業に反映)
 2. date_column の不整合(“TAX CLASS AT TIME OF SALE” が時系列として不適切)
 - 影響: time_ordered split や日付由来特徴の利用が妥当でなくなる可能性
 - 対策: A03 による実カラム確認(担当: 岡田/渡辺)を速やかに完了し、必要なら分割戦略を input_order に戻す
 3. 面積・築年等の欠損・異常(欠損補完がバイアス導入)
 - 対策: 欠損件数と分布を確定後、補完か除外かを前処理ルール案で合意(MS2/MS4 のゴール)
 4. 高カーディナリティ変数による過学習(NEIGHBORHOOD 等)
 - 対策: 頻度集約、カテゴリ集約、あるいは除外の基準を MS2 で確定
- 現状のアクション(短期)
 - 変更管理チェックポイント(2025-08-27)で、追加要求が発生した場合の工数影響を提示する(担当: 佐藤)
 - 中間報告で合意した前処理方針を早期に実装し、第 4 週のモデル化に反映する

6. 次回までの実施事項(トレース付き)

- 既存オープンアクション(Report facts.prior_state.open_actions を転記)
 - A01: 正式データ(data.csv)およびカラム説明の最終受領確認/不足ファイルの有無を報告
 - Owner: 前田 美咲(クライアント)、Due: 2025-08-08、Status: Open
 - A02: データ受領後の読込検証(読み込みエラー・エンコーディング・レコード数確認)および読込確認レポート提出
 - Owner: 岡田 佑樹、Due: 2025-08-08、Status: Open
 - A03: configs の date_column 実態確認(“TAX CLASS AT TIME OF SALE” が日付でない場合の修正案提示)
 - Owner: 岡田 佑樹/渡辺 遙、Due: 2025-08-08、Status: Open
 - A04: 第 1 週～第 2 週の詳細進め方(分析計画メモ草案)を取りまとめ、レビュー用ドラフトを共有
 - Owner: 藤田 彩(主担当)ほか、Due: 2025-08-12、Status: Open
 - A05: 欠損・ゼロ値・異常値の初期集計(件数・影響率)提示と前処理方針案作成
 - Owner: 岡田 佑樹/渡辺 遙、Due: 2025-08-15、Status: Open
 - A06: 中間報告資料(EDA 図表含む)ドラフト作成/内部レビュー実施
 - Owner: 渡辺 遙/藤田 彩、Due: 2025-08-25、Status: Open
 - A07: 変更管理チェックポイント(2025-08-27)向けの変更管理準備(追加要求時の工数見積テンプレ)作成
 - Owner: 佐藤 健一、Due: 2025-08-27、Status: Open
 - A08: 第 1 週～第 2 週計画及びデータ受領のクライアント承認取得
 - Owner: 前田 美咲(クライアント)、Due: 2025-08-08、Status: Open
- 次ステップ(優先度順)

1. A03 の完了: date_column 実態の確定(重要) → time_ordered split の妥当性最終判定(担当: 岡田/渡辺)
2. A05 の完了: 欠損件数の確定と前処理(補完 or 除外)基準の確定(担当: 岡田/渡辺)
3. A06 の完了: 中間報告用 EDA 図表の最終化(担当: 渡辺/藤田)
4. A07 に基づく変更管理テンプレ準備(担当: 佐藤)
5. 前処理ルール合意後、モデリング用分析データセット v1 を作成し(T13 相当)、第 4 週でベースラインの再実行とパラ調整

7. 経営/PM 向け補足

- 中間フェーズでの重要ポイント
 - チェックポイント段階は “interim”(Report facts.analysis.checkpoint_stage = “interim”)であるため、現時点のモデル実験は「初期検証」であり最終モデルや確定的なビジネス適用判断は未到達です。実験結果はあくまで方向性確認(非線形モデルが有望)に留めてください。
- 商務・工数(トレース)
 - 想定総工数(project facts / commercial terms): 170 時間(見込)
 - 見込金額(税抜): 4,250,000 円、消費税: 425,000 円、税込見込額: 4,675,000 円(支払条件は最終一括精算 / Report facts.commercial に準拠)
- 次回管理上のリスク指標
 - 未解決アクション数: 8(prior state.open_action_count)
 - クリティカルパス上のタスク遅延は最終報告(2025-09-16)と支払期日(2025-09-23)に影響する可能性あり。変更管理チェックポイント(2025-08-27)で工数影響の見積を取得することを推奨します。
- 参照資産(トレース)
 - 会議計画: artifacts/04a_meeting_plan.csv
 - 会議録: artifacts/meeting_minutes/会議録 2025-08-06.md
 - 分析ランサマリ: artifacts/analysis_outputs/run_summary.json
 - 分析メトリクス: artifacts/analysis_outputs/metrics.json
 - 実験リーダーボード: artifacts/analysis_outputs/experiments/leaderboard.json

以上。中間報告にて示した前処理ルール案・EDA 図表に基づき、承認を得られ次第(MS4 承認)、モデリングの第 2 フェーズ(特徴量調整・ハイパラ改善)へ移行します。