

会議録

1. 会議情報

会議ID: M02

会議種別: 分析方針レビュー

日付: 2025-05-27

目的: データ理解と品質確認結果を共有し欠損・外れ値・不均衡対応を含む前処理方針を確定する

主催: 株式会社データアステル（データサイエンス部）

議事録作成: 株式会社データアステル（ベンダ）→クライアント確認後確定

出席者: - 白峰信用リスク評価株式会社 審査企画部: 松原 陽介（部長） - 白峰信用リスク評価株式会社: 審査企画担当者（氏名省略） - 株式会社データアステル（データサイエンス部）: 伊藤 翔太、山本 彩乃、斎藤 悠斗、斎藤以外補助: 松本 真央、池田 恒一

（注）不明点の参加者名は TODO にて補記する箇所なし。

2. 議題

EDA / データプロファイリング結果の確認（欠損・外れ値・分布）

Attr37 を含む高欠損列の採否方針決定（比較実験ルール含む）

前処理ルール（欠損補完・外れ値処理・特徴量作成）と評価条件（分割・指標）の固定

不均衡対応の検討方針（手法比較・評価優先軸）

中間報告（M03）に向けた論点と必要成果物の確定

未解決アクションの確認（支払・単一正本等）

3. 主要議論

EDA確認

高欠損列、外れ値、不均衡対応の比較条件と評価条件を確認。ベースライン実行結果の共有は前処理仕様固定後に行う。

Attr37 採否方針

単純削除は行わず、投入あり/なしの2パターンで必ず比較実験することで合意。比較の評価条件・採否基準（下記「決定事項」参照）を明確化する必要あり。

前処理ルール（方針案の確認と合意）

欠損処理:

全変数共通ルールとして欠損フラグ（is_missing_*）を作成する（特に高欠損列で必須）。

欠損率が高い（ $\geq 30\%$ ）列は「補完+欠損フラグ」または「除外」の2案で比較。Attr37 はこれに該当。

一般数値列は中央値補完（train 分位で固定）を初期ルールとする。

外れ値処理:

まず列ごとの分布を確認し、基本は 1%/99% のパーセンタイルで winsorize（例: 1%-99%）を適用。正のみに偏る極端な列は対数変換の検討。

線形モデル用パイプラインと木系モデル用パイプラインで処理を分離（木系はスケーリング不要、線形は標準化）。

特徴量選定:

id は予測変数から除外（既合意）。Attr 系は業務観点と情報量を踏まえて列単位で採否判断を行う。

評価条件の固定

学習/評価分割: train/test = 80/20 (既実施と同一、test_rows=1,471 を使用)、分割は stratified (class) で固定、seed: 9186865 を使用 (再現性のため)。

評価指標: 再現率 (Recall) を最重視、補助指標として ROC-AUC、Precision@top10%、Brier score を算出。再現率の目標 (0.70) は当面参考値で、前処理固定後にベースラインで最終調整。

比較基準: Attr37 の採否は「投入あり」かつ「投入なし」の両条件で同一前処理・評価設定の下で比較する。

不均衡対応

初期方針はクラス重み付け (class_weight='balanced') および閾値調整。サンプリング手法 (オーバー/アンダー/SMOTE 等) は別途実験で比較 (T13)。

中間報告 (M03) 向け論点

Attr37 採否の最終判断 (MS4 期限: 2025-05-30 までに比較結果提示)

前処理仕様の最終確定 (前処理ルールドキュメント)

不均衡対応手法の比較結果 (再現率重視の評価)

上位10% リフト・業務示唆の暫定整理

4. 進捗サマリ

進捗概況

前処理仕様・評価条件は本会議で基本方針を固定。詳細は T12 (前処理仕様ドキュメント化) で確定。

マイルストーン状況 (主要)

MS1: キックオフ完了 (2025-05-13) — 完了 (既合意)

MS2: 着手事務完了 (2025-05-20) — 着手金未確認のため未達 (AI-05 フォロー中)

MS3: 分析方針確定 (2025-05-27) — 本会議で方針固定 (前処理方針、評価条件、Attr37 比較方針)

MS4: データ理解完了 (2025-05-30) — 予定どおり完了予定 (T12 の文書化を以て完了判断)

オープンアクション (要フォロー)

着手金支払確認 (AI-05): 期日超過のため優先フォロー (伊藤)

5. 決定事項

既存の主要合意事項の確認 (M01 の継続適用)

決定: 目的変数 class の定義 (0=存続、1=倒産)、id の予測変数除外、評価軸 (再現率最重視・ROC-AUC・上位10%集中度) は継続して適用。承認者: 出席全員。

Attr37 (高欠損列) の採否方針 (本会議決定)

決定: Attr37 は「投入あり / 投入なし」の2パターンで必須比較実験を行う。比較は同一前処理・評価設定で実施し、最終採否は MS4 (2025-05-30) までに下す。

採否判断基準 (定量基準): 「投入あり」が下記いずれかを満たす場合に投入を推奨する。

ROC-AUC の改善 $\Delta \geq 0.002$ かつ Recall (倒産クラス) を悪化させない ($\Delta \text{Recall} \geq -0.005$)

Precision@top10% が 0.01 以上改善し、説明可能性 (ドメイン上の妥当性) を損なわない場合

評価は testset (上記評価条件) で行い、改善幅は統計的に大きくはないが業務価値を勘案して最終決定する。承認者: 出席全員 (松原部長含む)。

前処理ルールの仮固定 (本会議決定)

欠損補完: 一般数値は中央値補完 (train の中央値を固定)、全高欠損列に対しては欠損フラグを作成。欠損率 $\geq 30\%$ の列は補完 + 欠損フラグ案と除外案を比較。

外れ値処理: 基本は 1%/99% winsorize。列によって対数変換を検討。線形系は標準化、木系は非標準化でパイプライン分離。

再現性: 前処理手順・パラメタを configs/project_config.json に記録しロックする。承認者: 出席全員。

評価条件の固定 (本会議決定)

学習/評価分割: train/test = 80/20 (stratified)、seed=9186865 を使用。

優先指標: 再現率 (Recall) を最重視、併せて ROC-AUC、Precision@top10%、Brier score を算出。承認者: 出席全員。

不均衡対応の実験方針 (本会議決定)

初期は class_weight='balanced' を採用。追加でサンプリング手法 (オーバー/アンダー/合成含む) を T1 3 で比較し、再現率向上効果を評価する。承認者: 出席全員。

中間報告 (M03) 向け必須論点 (本会議決定)

Attr37 採否結果 (比較表・数値根拠)、前処理仕様 (確定版)、不均衡対応比較 (再現率軸での比較)、上位10% の業務示唆 (暫定) を中間報告書に必須記載とする。承認者: 出席全員。

変更: - なし (M01 での既合意事項に対する変更は今回発生せず。もし決定基準を変更する場合は議事録と課題管理表で別途承認する。)

6. アクションアイテム

(Prior のアクションを継承し、完了/再スコープの理由を明記。新規は AI-08 以降)

ID	Action	Owner	Due Date	Status
AI-01	単一正本 (運営ルール・文言) の確定とプロジェクト文書への反映 (議事録作成フロー、変更管理手順を含む)	伊藤 翔太	2025-05-15	Closed (完了)
AI-02	data/train.csv の正式受領確認とアクセス権限付与の実施 (受領ファイルのハッシュ確認、アクセス手順記録)	斎藤 悠斗	2025-05-16	Closed (受領・アクセス確認済、EDA 実行により確認)
AI-03	分析方針レビュー資料作成 (前処理案、Attr37 等高欠損列の採否比較案、評価指標定義・計測方法の詳細)	山本 彩乃	2025-05-26	Closed (会議資料として提出・レビュー実施)
AI-04	詳細スケジュール・課題管理表の作成 (WBS/Tタスクを反映) および共有	伊藤 翔太	2025-05-16	Closed (スケジュール配布済、参照: スケジュール資料)
AI-05	着手金請求書の発行と支払確認 (請求記録の送付、支払ステータス確認)	伊藤 翔太	2025-05-20	Open (期日超過: 会議で即時フォロー指示。クライアント側確認を要)
AI-06	キックオフ議事録 (正式版) 作成・配布 (ベンダ作成 → クライアント確認)	伊藤 翔太 / 松本 真央	2025-05-14	Closed (配布・クライアント確認済)
AI-07	データプロファイリング (EDA) 初版の作成 (欠損・外れ値・分布・クラス分布含む)	斎藤 悠斗 / 山本 彩乃	2025-05-21	Closed (EDA 出力を artifacts にて確認)

AI-08	前処理仕様書（前処理ルール・欠損補完方法・外れ値処理・欠損フラグ作成ルール・線形/木系パイプライン差分）作成・レビュー反映	山本 彩乃 / 斎藤 悠斗	2025-05-30	Open
AI-09	Attr37 を含む/除外の2パターン比較実験実施（同一評価設定での ROC-AUC / Recall / Precision@top10% の差分表作成）	山本 彩乃	2025-05-30	Open
AI-10	不均衡対応比較（class_weight / サンプルング手法）を実施し、再現率重視の評価表を作成	山本 彩乃	2025-06-13	Open
AI-11	中間報告（M03）ドラフト作成（必須論点を含む: Attr37 比較、前処理確定版、不均衡比較、上位10%業務示唆）	松本 真央 / 山本 彩乃	2025-06-12	Open

閉鎖理由（Closed のもの）

AI-01: 単一正本運用ルールを文書化しプロジェクト文書群へ反映済み（伊藤報告）。クライアント確認済み。

AI-02: データファイル受領とアクセス権限が確認され、EDA が実行されているため完了と判断。

AI-03: 分析方針レビュー資料を期日までに提出し、本会議でレビュー・合意を得たため完了。

AI-04: 詳細スケジュールと課題管理表は共有済み（参照: スケジュール資料）、会議で確認済み。

AI-06: キックオフ議事録は配布・確認済み。

7. リスクと懸念事項

開発・成果物リスク（現状）

着手金未入金リスク（AI-05 Open）

影響: リソース確保・工数配分に影響、進行に制約が出る可能性。

対応: 伊藤がクライアントと即時確認、必要なら松原部長へエスカレーション。期日は既過（2025-05-20）。

Attr37 の採否によるバイアス・情報損失リスク

影響: 補完方法によるバイアス、説明可能性低下の可能性。

対応: 投入/除外の2案で定量比較（AI-09）、説明可能性評価を定性的に併記。

クラス不均衡による評価バイアス

影響: Accuracy 等誤認のリスク、再現率確保が難航する可能性。

対応: 不均衡対応手法の比較（AI-10）、再現率を最重視して閾値調整を実施。

外れ値多数による学習安定性低下

影響: モデルの過学習や評価変動。

対応: 列単位の winsorize/変換を適用し線形系と木系で比較（AI-08）。

未解決事項（Open issues）

AI-05（着手金支払確認）の解決状況確認が未完了。次回会議までにクライアント回答を得る必要あり。

Attr37 に関する最終採否は AI-09 結果に依存（期限: 2025-05-30）。

エスカレーション基準

着手金未確認が 3 営業日以内に解消されない場合、PM（伊藤）から松原部長へ書面でエスカレーション。
AI-08/AI-09 が 2025-05-30 までに完了せず、MS4（2025-05-30）に間に合わない場合は中間レビュー日程へ影響するため即時再計画を実施。

8. 次回会議計画

次回会議: M03（中間レビュー）

日時: 2025-06-17（予定・既スケジュール）

目的: ベースライン比較結果（前処理固定後）、不均衡対応比較、Attr37 最終採否報告（AI-09 結果）および中間報告ドラフト確認

提出物（次回までに担当が用意するもの）

山本: Attr37 比較実験結果（AI-09） — 提出期限 2025-05-30（会議内で暫定報告、M03 で確定）

山本 / 斎藤: 前処理確定版ドキュメント（AI-08） — 期限 2025-05-30

山本: 不均衡対応比較レポート（AI-10） — 期限 2025-06-13

松本 / 山本: 中間報告ドラフト（AI-11） — 期限 2025-06-12（レビュー用）

次回アジェンダ（案）

Attr37 比較結果と採否判断（数値+説明可能性）

前処理確定版の最終承認（欠損・外れ値・変換ルール）

不均衡対応比較結果の確認（再現率優先）

中間報告ドラフト合意事項の確認

着手金支払状況の最終確認（伊藤報告）

以上。