

分析進捗報告書

1. 報告サマリー

チェックポイント: M03（中間レビュー） — 日付: 2025-06-17

報告対象期間: 2025-05-13 ～ 2025-06-17（スコープは当初定義の data/train.csv を用いた分析作業）

現時点のステータス（サマリ）:

レコード数（全体）: 7,352 件

学習行数: 5,881 行 / テスト行数: 1,471 行

特徴量数（説明変数想定）: 65

未完了・未解決の主要アクションが残存（Open アクション数: 5、詳細はセクション6）。

2. 進捗状況

完了済み（本チェックポイント時点）

結果を 04.分析/analysis_outputs 配下に格納。

議事録・合意事項は会議録（05.会議/会議録/会議録_2025-06-17.docx）に記録

進行中／未完了

前処理仕様書の最終確定（AI-08）: 担当: 山本 彩乃 / 斎藤 悠斗 — 期限 2025-05-30（現時点で Open／要フォロー）

Attr37 の投入可否比較実験（AI-09）: 担当: 山本 彩乃 — 期限 2025-05-30（現時点で Open／要フォロー）

不均衡対応手法比較（AI-10）: 担当: 山本 彩乃 — 期限 2025-06-13（現時点で Open／要フォロー）

中間報告ドラフト（AI-11）: 担当: 松本 真央 / 山本 彩乃 — 期限 2025-06-12（現時点で Open／要フォロー）

着手金支払確認（AI-05）: 担当: 伊藤 翔太 — 期限 2025-05-20（期日超過、クライアント側の対応待ち）

スケジュールとのトレース（主要マイルストーン）

MS1 キックオフ（2025-05-13）: 完了

MS3 分析方針確定（2025-05-27）: 完了（前処理方針・評価条件を仮固定）

MS5 中間レビュー（2025-06-17）: 本日実施（本レポートの対象）

3. 主要な分析結果

データ品質（EDA）に関する定量要点（EDA 出力に基づく）

欠損率上位（top10）:

Attr37: 0.45252992383025026 （約45.25%）

Attr21: 0.07236126224156691 （約7.24%）

Attr27: 0.07113710554951033 （約7.11%）

Attr60: 0.055767138193688795 （約5.58%）

Attr45: 0.05563112078346028 （約5.56%）

その他（Attr53/64/54/28/24）: 各々約2.1%～2.08% 程度

注記: Attr37 は欠損率が特に高く（≈45%）、投入の是非は定量的比較（投入あり/なし）により判断する方針（M02 で合意の比較ルールに従う）。

trial_index 1～5 の比較結果では、random_forest が primary_metric=f1_macro 0.49989801、secondary_metric=accuracy 0.94901428 で最良。

解釈:

中間レビュー時点では random_forest が F1(macro) と Accuracy の両面で最良であり、以降は Attr37 の採否としきい値設計を詰める。

前処理方針 (M02 合意の要点、実装前提)

欠損補完: 一般数値は train 中央値で補完、欠損フラグを作成。欠損率 $\geq 30\%$ の列は「補完 + 欠損フラグ」案と「除外」案を比較 (Attr37 が該当)。

外れ値処理: 1%/99% パーセンタイルの winsorize を基本方針。線形系と木系で処理を分離。

評価分割: train/test = 80/20 (stratified)、seed 固定 (seed: 9186865) により再現性を確保。

4. データ品質と実装状況

データ品質 (現状)

行数・列数: 7,352 行 / 66 列 (ソース定義)。metrics 側の feature_count は 65 (説明変数カウント) として記録済み。

高欠損列: Attr37 ($\approx 45.25\%$) は情報量と欠損バイアスの双方を考慮し、投入有無の比較を必須としている (AI-09)。

外れ値: 複数列で極端値が存在するため、列毎に変換/winsorize 等の検討が必要 (M02 合意)。

実装状況 (成果物の場所と内容)

分析出力:

再現性:

学習・評価は固定シードと stratified split にて再現可能。

未実装/未確定事項

前処理仕様書 (AI-08) 未確定: 前処理パラメータ (winsorize の閾値、欠損補完ルールの最終版等) をドキュメント化し、再現性を担保する必要あり。

Attr37 の最終採否 (AI-09) が未決定のまま。比較結果に基づく MS4/MS5 の判断が必要。

5. リスクと対応策

主要リスク

支払関連リスク (商務)

状況: 着手金支払確認 (AI-05) が期日 (2025-05-20) を過ぎて未完了。

影響: ベンダ側のリソース配分、速やかな次工程着手に影響を与える可能性。

対応: PM (伊藤) がクライアントへフォローアップ、必要に応じて松原部長へエスカレーション。支払条件・金額は契約に基づく (着手金: 税込 2,992,000 円/検収金: 税込 4,488,000 円、契約金額税込 7,480,000 円)。

高欠損列 (Attr37) によるバイアス・情報損失

状況: 欠損率 $\approx 45\%$ (EDA)。

影響: 補完によるバイアス、説明可能性低下、モデル性能評価への影響。

対応: 「投入あり/なし」の必須比較 (AI-09)。採否判定基準は M02 で合意 (例: ROC-AUC の改善 $\Delta \geq 0.002$ かつ Recall を著しく悪化させない等の定性的/定量的基準を参照) ※採否は比較結果で決定。

クラス不均衡 (倒産クラスの希少性)

状況: 不均衡データに起因する学習バイアスのリスク。

外れ値によるモデル安定性低下

対応: 列別に winsorize／対数変換を比較適用し、線形系と木系で最適化。

追加対応（プロジェクト運営上）

変更管理チェックポイント（MS6: 2025-06-18）を活用し、契約範囲外要求の混入有無を確認する。追加開発は別紙見積で対応。

6. 次回までの実施事項（アクション、オーナー、期日）

現時点での Open アクション（Report facts に基づく）

AI-05: 着手金請求書の発行と支払確認

オーナー: 伊藤 翔太

期日: 2025-05-20（期日超過、要クライアント対応／最優先フォロー）

AI-08: 前処理仕様書（前処理ルール・欠損補完・外れ値処理等）作成・レビュー反映

オーナー: 山本 彩乃 / 斎藤 悠斗

期日: 2025-05-30（期限経過／要完了）

オーナー: 山本 彩乃

期日: 2025-05-30（期限経過／要完了）

AI-10: 不均衡対応比較（class_weight / サンプルング等） — 再現率重視の評価表作成

オーナー: 山本 彩乃

期日: 2025-06-13（期限経過／要完了）

AI-11: 中間報告（M03）ドラフト作成（Attr37 比較、前処理確定版、不均衡比較、上位10% 示唆を含む）

オーナー: 松本 真央 / 山本 彩乃

期日: 2025-06-12（期限経過／要完了）

次の短期優先タスク（推奨順・期日）

着手金の支払確認（AI-05） — 即時エスカレーション/確認（経営向け注視事項）

前処理仕様書の確定（AI-08） — 再現性確保のため最優先で完成させること（MS6 の判断材料にもなる）

Attr37 比較実験の完了と採否判断（AI-09） — 採否は中立的な定量基準で決定すること

不均衡対応比較の完了（AI-10） — 再現率改善の効果を定量化すること

中間報告ドラフトの確定・配布（AI-11） — クライアント確認を得て次フェーズへ移行

近接マイルストーン（リマインド）

MS6 変更管理チェックポイント: 2025-06-18（M03 の直後） — 契約範囲逸脱がないかを確認予定

MS7 モデル比較・説明資料完成: 2025-07-04（次フェーズ目標）

MS8 最終レビュー: 2025-07-15、MS9 検収金支払期日: 2025-07-22

7. 経営/PM向け補足

財務・契約状況（Report facts / Project facts に基づく）

契約金額（税抜）: 6,800,000 円

消費税率: 10% → 消費税額: 680,000 円

契約金額（税込）: 7,480,000 円

支払スケジュール（契約に基づく）：

着手金（40%）：金額（税込）2,992,000 円（期日：契約締結後5営業日以内） — 現在支払確認が未完了（AI-05、期日超過）。

検収金（60%）：金額（税込）4,488,000 円（期日：最終成果物検収後5営業日以内）

固定価格契約のため、追加作業は別紙見積で事前合意が必要（変更管理方針の運用を厳守）。

重要判断ポイント（経営判断が必要となる可能性）

着手金未入金が解消しない場合、リソース確保とスケジュール維持に影響が出るため、クライアント側への迅速な対応依頼（PM レベルでのエスカレーション）を推奨。

Attr37 の扱いにより解析方針や説明責任に影響が出る可能性があるため、採否判断は定量基準に基づき迅速に実施することを推奨。

注意事項

今後は「前処理仕様の確定」と「不均衡対応の比較」を優先し、M04（最終レビュー）までに最終モデル候補と採用根拠を揃える必要あり。